

IM01 : Segmentation de lésions cutanées

NADIEDJOA Théophile & NADANAKUMAR Agshay
Encadré par GORI Pietro

Novembre 2025

Introduction

Le mélanome représente aujourd’hui un enjeu majeur de santé publique, étant considéré comme la forme de cancer cutané la plus agressive. L’impact de cette pathologie est significatif : les statistiques aux États-Unis font état d’environ 10 000 décès annuels pour 40 000 à 50 000 cas diagnostiqués. Pourtant, le pronostic vital des patients dépend étroitement de la rapidité de la prise en charge. Une détection précoce augmentant considérablement les chances de survie, toute amélioration technologique des outils de dépistage est susceptible de réduire la mortalité associée à ce cancer.

Actuellement, la dermoscopie constitue la technique d’imagerie de référence. Elle permet d’éliminer les réflexions de surface pour observer les structures sous-cutanées, améliorant ainsi la sensibilité du diagnostic par rapport à un examen clinique simple. Toutefois, l’analyse de ces images demeure une tâche complexe, sujette à la subjectivité et à la variabilité inter-opérateur, même pour des dermatologues expérimentés. L’apport de l’informatique, via les systèmes de Diagnostic Assisté par Ordinateur (CAD), est donc crucial pour offrir une évaluation plus objective, standardisée et reproductible. Ces systèmes reposent sur des algorithmes de segmentation dont le rôle est de délimiter précisément la zone pathologique.

Dans le cadre du projet « Segmentation de Lésions Cutanées », nous nous attachons à automatiser cette étape critique d’isolation des lésions pigmentées à partir d’images dermoscopiques. Notre démarche est guidée par une contrainte spécifique : l’utilisation exclusive de techniques classiques de traitement d’image, sans recours à l’apprentissage profond. L’objectif final est d’extraire un masque binaire de la lésion, prérequis indispensable à toute analyse quantitative ultérieure. Ce rapport détaillera d’abord les étapes de prétraitement, nécessaires pour nettoyer les images de leurs artefacts (poils, bordures). Nous présenterons ensuite la mise en œuvre et la comparaison de différentes méthodes de segmentation afin d’évaluer leur pertinence face à la diversité des cas cliniques.

1 Prétraitement des images dermoscopiques

1.1 Suppression du cadre (Frame Removal)

De nombreuses images dermoscopiques présentent un cadre sombre autour de la zone utile, souvent lié au dispositif d'acquisition ou à un masque physique (vignettage). Ces bordures noires peuvent être confondues avec la lésion ou perturber les algorithmes de segmentation en créant un contraste artificiel. Elles risquent ainsi d'altérer la détection correcte des contours. Il est donc essentiel de supprimer ce cadre avant toute segmentation.

Pour répondre à ce problème, nous avons exploré deux approches successives.

1.1.1 Première approche : Recadrage rectangulaire par balayage

Dans un premier temps, nous avons implémenté un algorithme de recadrage itératif. Le principe reposait sur un balayage des lignes et des colonnes depuis les bords de l'image vers le centre. L'algorithme calculait la proportion de pixels noirs sur chaque ligne ; dès que cette proportion passait sous un seuil (indiquant la présence de peau), le balayage s'arrêtait pour définir les limites de recadrage (crop).

Limites constatées : Cette méthode reposait sur l'hypothèse implicite que la zone d'intérêt (la peau) était rectangulaire et alignée avec les bords de l'image. Cependant, sur certaines images de notre jeu de données (Figure 1), les dermatoscopes produisent souvent une zone de vue circulaire. Cette limitation nous a conduits à abandonner cette approche au profit d'une méthode plus robuste prenant en compte la géométrie circulaire.

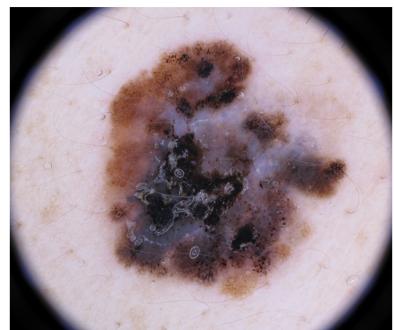
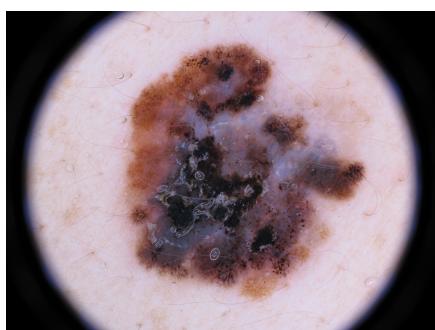


FIGURE 1 – Illustration de la suppression du cadre - Première approche. À gauche : l'image dermoscopique brute présentant un fort vignettage (coins sombres). À droite : résultat après algorithme, on observe toujours des bords noirs sur les coins.

1.1.2 Seconde approche : Segmentation morphologique et masquage circulaire

Pour pallier les défauts de la première méthode, nous avons développé une approche "géométrique". Au lieu de chercher à éliminer les bords ligne par ligne, l'objectif est d'identifier directement la zone de peau centrale comme un objet, puis de masquer tout le reste.

L'algorithme repose sur l'hypothèse que la zone de peau éclairée forme un disque clair situé approximativement au centre de l'image. Le fonctionnement du code s'organise autour des étapes suivantes :

1. **Analyse de la bordure de l'image** : Une inspection préliminaire des bords (sur une bande de 5% de la largeur) permet de calculer la proportion de pixels noirs. Si cette proportion est faible, l'image est considérée comme sans bordure et aucun traitement n'est appliqué.
2. **Seuillage global et Composantes Connexes** : L'image est convertie en niveaux de gris puis seuillée pour séparer les zones claires (peau) du fond sombre. L'analyse des composantes connexes nous permet de sélectionner la région la plus grande, éliminant ainsi le bruit ou les reflets isolés.
3. **Modélisation géométrique** : La composante principale (la peau) est approximée par un disque dont nous calculons le centre de gravité et le rayon optimal.
4. **Masquage et Recadrage final** : Un masque binaire circulaire est généré. Tout ce qui se trouve à l'extérieur de ce cercle est remplacé par du blanc (255), éliminant parfaitement les coins noirs, quelle que soit leur forme. Enfin, un recadrage rectangulaire est effectué autour de ce cercle.

La Figure 2 illustre l'efficacité de cette seconde méthode. Le cadre noir de l'image initial a été totalement éliminé, enlevant même les coins.

Discussion et perspectives : Cette étape de prétraitement est cruciale et s'est avérée robuste pour la majorité des images "standards". Toutefois, l'approche par seuillage simple peut montrer ses limites dans des cas complexes, par exemple si le cadre est partiellement réfléchissant ou si l'éclairage est très hétérogène. Une amélioration possible serait d'intégrer des techniques de correction de l'ombrage [2], qui modélisent la variation d'éclairage par une fonction quadratique pour mieux isoler la peau. Dans le cadre de ce projet, la méthode actuelle a fourni des résultats suffisants pour permettre une segmentation efficace des lésions.



FIGURE 2 – Illustration de la suppression du cadre - 2e approche. Le cadre noir autour de l'image a bien été retiré, laissant juste le mélanome.

1.2 Suppression des poils (Hair Removal)

Les images dermoscopiques contiennent souvent des poils qui traversent la lésion ou la peau environnante. Ces artefacts peuvent fausser les algorithmes de segmentation en étant interprétés à tort comme des contours ou des structures internes à la lésion. Afin d'améliorer la qualité des masques de segmentation, une étape de suppression des poils s'avère donc indispensable.

Nous avons basé notre approche sur l'algorithme de référence *DullRazor* [1], qui repose sur le principe de la fermeture morphologique pour détecter les structures sombres et fines. Notre implémentation a suivi un processus itératif en deux temps.

1.2.1 Première approche : Implémentation naïve et limites

Dans un premier temps, nous avons testé une implémentation standard utilisant des éléments structurants linéaires fins (largeur de 1 pixel) et un seuillage global élevé (fixé à 250 sur l'image de différence).

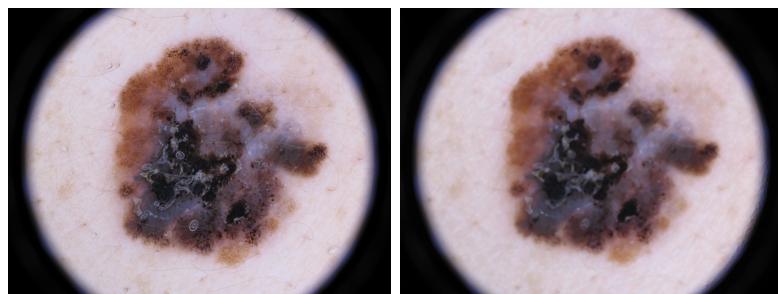


FIGURE 3 – Implémentation de la méthode 1 : Poils fins sont bien enlevés

Analyse de l'échec : Cette méthode a montré des limites critiques sur les images présentant des poils épais ou peu contrastés.

1. **Problème d'échelle :** L'élément structurant étant plus fin que certains poils, l'opération de fermeture morphologique s'exécute "à l'intérieur" du poil sans le supprimer, rendant la détection impossible.
2. **Problème de seuil :** Le seuil de 250 exigeait un contraste quasi-maximal (noir sur blanc). Or, la différence d'intensité réelle entre un poil brun et la peau oscille souvent entre 20 et 50. Le masque binaire résultant était donc majoritairement vide, empêchant toute interpolation.

1.2.2 Seconde approche : Pipeline robuste optimisé

Pour corriger ces défauts, nous avons développé une version améliorée ("Macro-DullRazor") capable de détecter les structures complexes sans dégrader la texture de la peau.

Voici les améliorations techniques du pipeline final :

1. **Fermeture multi-directionnelle :** Au lieu de simples lignes, nous utilisons des éléments structurants rectangulaires (épaisseur de 10 pixels) orientés selon 2 axes.
2. **Détection et Dilatation du masque :** Le masque de poils est obtenu par différence absolue entre l'image originale et l'image fermée. Nous avons abaissé le seuil de détection à **40** (au lieu de 250). Ce seuil, bien que plus bas, reste suffisant pour ignorer les faibles variations de texture de la peau tout en captant les poils, grâce au fort contraste généré par les éléments structurants larges. *Amélioration critique :* Dilatation par un carré pour inclure les bords flous des gros poils.
3. **Interpolation et Lissage :** Les zones masquées sont reconstruites par interpolation (*Grid Data Interpolation*) basée sur le voisinage immédiat. Un filtre médian final (fenêtre 5×5) est appliqué pour fondre les corrections et assurer une transition naturelle avec la peau saine.

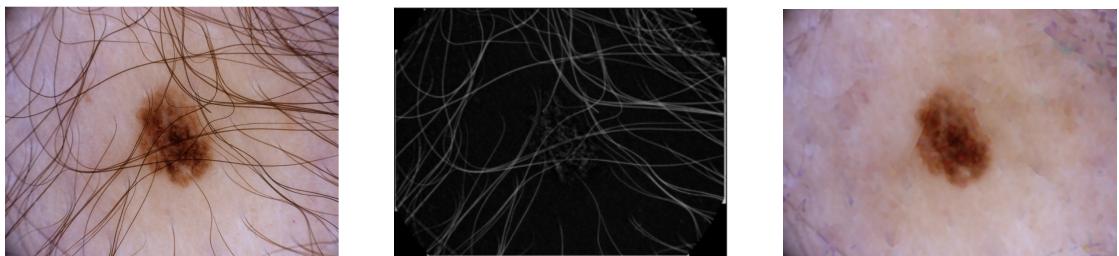


FIGURE 1 – Résultat du pipeline optimisé : (a) Image originale (b) Masque binaire du canal rouge (c) Résultat final après interpolation.

Cette approche optimisée offre un compromis idéal : elle est assez sensible pour détecter les poils fins (grâce au seuil bas) et assez robuste pour ne pas détruire la texture de la peau (grâce au filtrage morphologique).

2 Comparaison de méthodes de segmentation des lésions cutanées

Après avoir nettoyé les artefacts (cadres, poils) lors du prétraitement, l'étape critique consiste à isoler la lésion pigmentée de la peau saine. La littérature scientifique propose de nombreuses approches, allant du seuillage simple aux modèles déformables. Dans le cadre de ce projet, nous avons choisi d'implémenter et de comparer trois familles d'algorithme représentatifs : une méthode basée sur l'histogramme (Otsu), une méthode basée sur la texture (LBP Clustering) et une méthode basée sur la fusion de régions (SRM).

Chacune de ces méthodes a été implémentée en Python, optimisée, et évaluée sur un jeu de données varié comprenant des cas cliniques complexes (lésions pâles, naevus hétérogènes, présence de bruits résiduels).

2.1 Méthode 1 : Seuillage d'Otsu « Multi-Canal »

2.1.1 Principe théorique

La méthode d'Otsu est l'approche la plus classique pour la binarisation d'images. Elle repose sur l'hypothèse que l'histogramme des intensités de l'image est bimodal (deux pics distincts : le fond et l'objet). L'algorithme recherche le seuil T optimal qui minimise la variance intra-classe, ou de manière équivalente, maximise la variance inter-classe $\sigma_B^2(T)$ définie par :

$$\sigma_B^2(T) = \omega_0(T)\omega_1(T)[\mu_0(T) - \mu_1(T)]^2$$

Où ω_0, ω_1 sont les probabilités d'occurrence des classes (peau/lésion) et μ_0, μ_1 leurs moyennes respectives.

2.1.2 Implémentation et Optimisation Multi-Canal

La performance d'un seuillage global dépend drastiquement de l'espace de couleur utilisé [3]. Une lésion peut être invisible dans le canal Rouge (où la peau et la mélanine réfléchissent la lumière de manière similaire) mais apparaître très contrastée dans le canal Bleu ou Vert.

Pour rendre notre segmentation robuste, nous avons développé une approche « Multi-Canal » :

1. L'image est décomposée en ses canaux individuels (Rouge, Vert, Bleu) ainsi qu'en sa version Niveaux de Gris (luminance).
2. Le seuillage d'Otsu est calculé indépendamment pour chaque canal.
3. Un critère de sélection automatique retient le masque le plus pertinent. Nous avons observé que le canal Bleu ou la Luminance offraient souvent les meilleurs résultats pour les lésions brunes, tandis que le canal Vert était plus performant pour les lésions vasculaires.

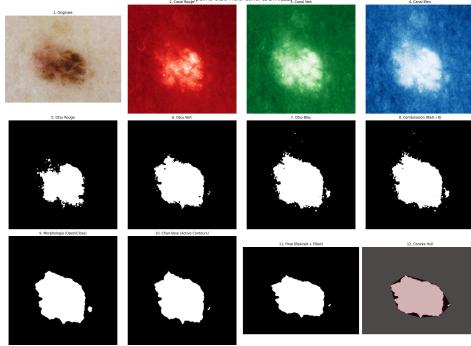


FIGURE 5 – Visualisation du pipeline Otsu Multi-Canal. L’algorithme teste les différents canaux et retient automatiquement celui qui maximise le contraste pour la segmentation.

2.1.3 Limitations observées

Malgré sa rapidité d’exécution, la méthode d’Otsu montre des limites intrinsèques sur notre base de données :

- **Dépendance à l’éclairage** : La méthode étant globale, elle échoue si l’image présente un fort vignettage ou des ombres portées. Dans ces cas, l’ombre est segmentée comme faisant partie de la lésion (sur-segmentation).
- **Faible contraste** : Pour les mélanomes débutants ou très pâles, l’histogramme n’est pas clairement bimodal. Le seuil calculé tend alors à fusionner la lésion avec la peau environnante, entraînant une sous-segmentation critique.

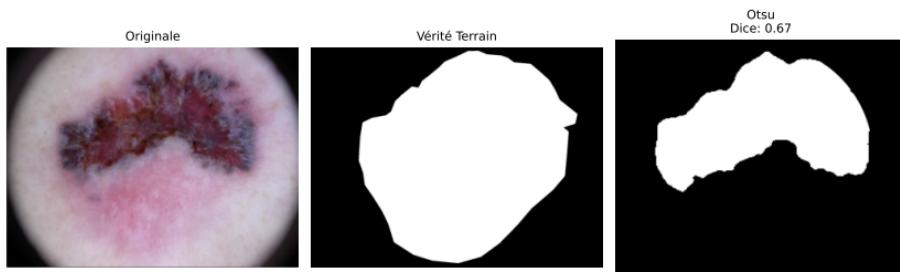


FIGURE 6 – Exemple d’échec d’Otsu : seule la partie la plus foncée de la lésion est segmentée en raison d’un seuil global trop restrictif.

2.2 Méthode 2 : LBP Clustering (Texture et Couleur)

Les approches par seuillage simple échouent lorsque la couleur de la lésion est trop proche de celle de la peau. Pour pallier cela, nous avons implémenté

une méthode basée sur la texture, qui exploite les *Local Binary Patterns* (LBP) [3].

2.2.1 Descripteurs de texture et d'espace couleur

L'hypothèse fondamentale est que la peau saine présente une texture lisse et régulière, tandis que la lésion présente une texture chaotique (réseau pigmentaire, globules).

1. **Espace CIELab** : Nous convertissons l'image dans l'espace perceptuel CIELab. Contrairement au RGB, cet espace sépare la luminance (L) de la chrominance (a et b). Nous ne conservons que les canaux a (axe vert-rouge) et b (axe bleu-jaune) pour nous affranchir des variations d'éclairage.
2. **Extraction LBP** : Nous calculons les motifs binaires locaux sur la composante de luminance. Pour chaque pixel, nous comparons son intensité avec ses 8 voisins (rayon $R = 1$). Cela génère une carte de texture insensible aux changements monotones de gris.

2.2.2 Classification non supervisée (K-Means)

Nous construisons pour chaque pixel un vecteur de caractéristiques de dimension 3 : $[LBP, a, b]$. Un algorithme de clustering K-Means (avec $k = 2$) est ensuite appliqué pour partitionner l'image en deux groupes. Cette approche s'est révélée particulièrement puissante. Là où Otsu hésite sur une frontière floue, le LBP parvient à discriminer la lésion grâce à sa rugosité de surface, même si sa couleur est similaire à la peau.

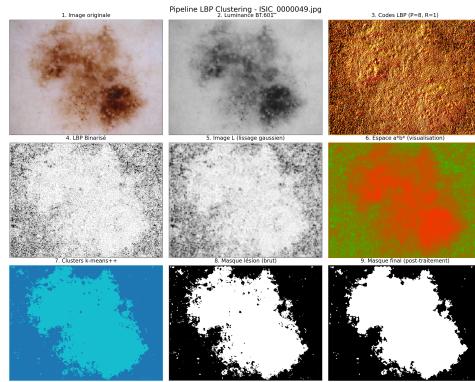


FIGURE 7 – Visualisation du pipeline LBP Clustering. On observe l'extraction des motifs de texture (LBP Map), puis le clustering K-Means qui sépare la lésion (texture rugueuse) de la peau saine (texture lisse).

2.3 Méthode 3 : Statistical Region Merging (SRM) Optimisée

La méthode SRM [4] est une technique de segmentation par croissance de régions. Elle considère initialement chaque pixel comme une région, puis fusionne itérativement les régions adjacentes si elles sont statistiquement similaires, selon un prédictat de fusion dépendant d'un paramètre d'échelle Q . Cependant, l'application « naïve » de SRM a produit des résultats décevants sur nos cas complexes. Nous avons donc dû profondément modifier l'algorithme pour l'adapter aux spécificités biologiques des lésions cutanées.

2.3.1 Problématique des lésions pâles : Le « Canal Bleu »

Nous avons rencontré un cas d'échec majeur avec l'image ISIC_0000024, une lésion très pâle presque invisible en niveaux de gris. L'algorithme SRM standard ne parvenait pas à la distinguer de la peau (Dice proche de 0).

Notre solution : Nous nous sommes appuyés sur les propriétés optiques de la peau. La mélanine absorbe préférentiellement les courtes longueurs d'onde. Nous avons donc forcé l'algorithme à travailler exclusivement sur le Canal Bleu. Cette modification simple a eu un impact spectaculaire : le contraste apparent de la lésion a été multiplié, permettant une segmentation précise là où l'approche RGB échouait totalement.

2.3.2 Problématique des lésions hétérogènes : La Fusion Multi-Régions

Un autre défi est apparu avec les lésions polychromes (ex : ISIC_0000049), présentant un cœur noir et une périphérie brune. L'algorithme standard sélectionnait la région la plus sombre (le cœur) mais ignorait la périphérie, conduisant à une sous-estimation de la surface.

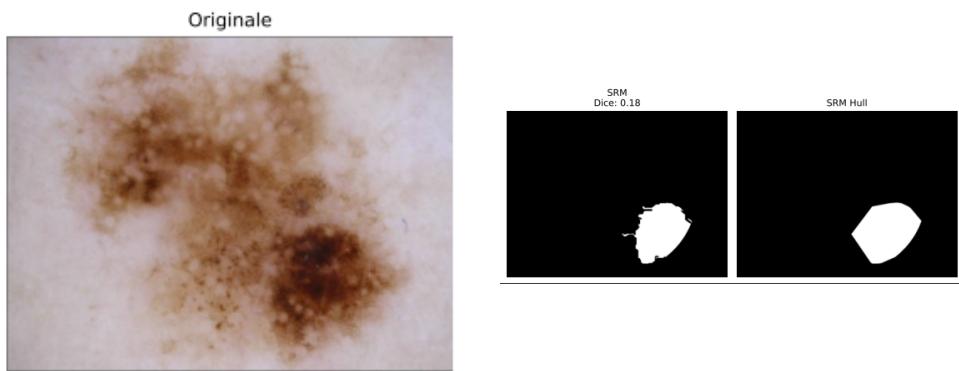


FIGURE 8 – Gauche : Exemple d'une lésion polychrome. Droite : Difficulté initiale de détection (avant optimisation Fusion).

Notre solution : Nous avons développé une heuristique de « repêchage » (Fusion Multi-Régions). L'algorithme calcule un score pour chaque région segmentée, combinant :

- Le **Contraste** par rapport à la peau (estimée via le 70ème percentile des bords pour éviter le biais du vignettage).
- La **Centralité** (probabilité a priori que la lésion soit au centre).
- La **Saturation** (composante S du HSV), pour détecter les zones érythémateuses (rouges) qui peuvent être claires mais pathologiques.

Au lieu de ne garder que la meilleure région, nous fusionnons désormais la région « championne » avec toutes les régions voisines ayant un score suffisamment proche ($> 60\%$ du max). Cela permet de reconstruire l'intégrité anatomique de la lésion.

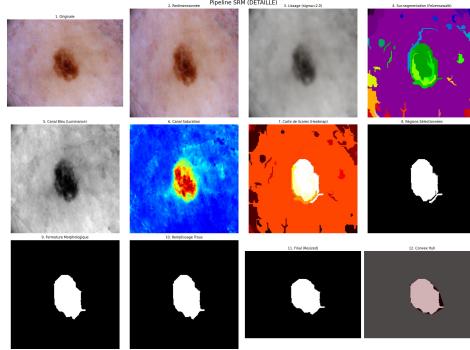


FIGURE 9 – Pipeline complète de la méthode SRM optimisée.

2.4 Problématique du bruit : L'enveloppe convexe intelligente (« Smart Hull »)

Enfin, l'utilisation de l'enveloppe convexe (`convex_hull`) pour lisser les bords est une pratique courante, mais risquée. Sur certaines images, un petit artefact résiduel dans un coin a provoqué la génération d'un masque triangulaire aberrant couvrant toute l'image.

Notre solution : Nous avons implémenté un filtre spatial `smart_hull`. Avant de calculer l'enveloppe, cet algorithme analyse les composantes connexes du masque. Il ne conserve les petites taches satellites que si elles sont situées à une distance cohérente du noyau principal (inférieure à 2,5 fois le rayon équivalent). Les bruits lointains sont ainsi éliminés, garantissant une forme convexe pertinente.

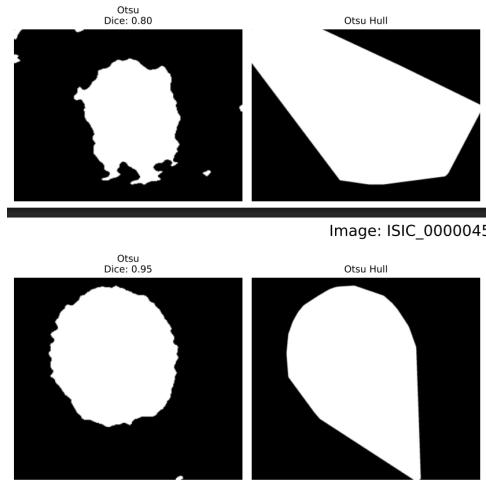


FIGURE 10 – Illustration du problème de l’enveloppe convexe lorsqu’il y a des petits artefacts résiduels.

3 Résultats et Discussion

3.1 Analyse Quantitative Globale

L’évaluation quantitative de nos algorithmes sur le jeu de données de test révèle une hiérarchie des performances différente de nos attentes théoriques initiales. Les résultats sont synthétisés dans le Tableau I

On remarque deux tendances majeures :

1. **L’impact du post-traitement (Hull)** : L’application de l’enveloppe convexe intelligente (*Smart Hull*) améliore systématiquement les scores Dice pour toutes les méthodes, avec un gain particulièrement notable pour la méthode d’Otsu et le LBP. Cela confirme que le lissage des bordures et le remplissage des trous sont des étapes indispensables.
2. **La (légère) domination de LBP et Otsu** : Contrairement aux hypothèses posées lors de la conception du SRM, ce sont les méthodes **LBP Clustering** et **Otsu Multi-Canal** qui obtiennent les meilleurs scores moyens, dépassant régulièrement 0,85 une fois combinées au *Hull*. Le SRM Optimisé, bien que plus complexe, affiche des performances moyennes en retrait.

Méthode	Dice Moyen (Brut)	Dice Moyen (Avec Hull)
Otsu Multi-Canal	0,84	0,90
LBP Clustering	0,86	0,90
SRM Optimisé	0,79	0,84

TABLE 1 – Performances moyennes par méthode. Le LBP Clustering avec Hull offre la meilleure fiabilité globale.

3.1.1 Analyse détaillée : Mélanomes vs Nævus

La Figure 11 permet d'affiner cette analyse en distinguant les pathologies.

- **Mélanomes (Graphique du haut)** : C'est sur ces cas complexes que la différence se creuse. On observe une plus grande variance des résultats (barres d'erreur plus grandes). Ici encore, le LBP et Otsu maintiennent une robustesse appréciable. Le SRM montre ses limites sur ces textures hétérogènes, avec une moyenne visiblement inférieure aux deux autres méthodes.
- **Nævus (Graphique du bas)** : Sur ces lésions généralement homogènes, toutes les méthodes obtiennent de bons résultats. Cependant, le couple **LBP + Hull** et **Otsu + Hull** atteignent des scores d'excellence (proches de 0.95), montrant une très grande fiabilité. Le SRM reste légèrement en dessous.

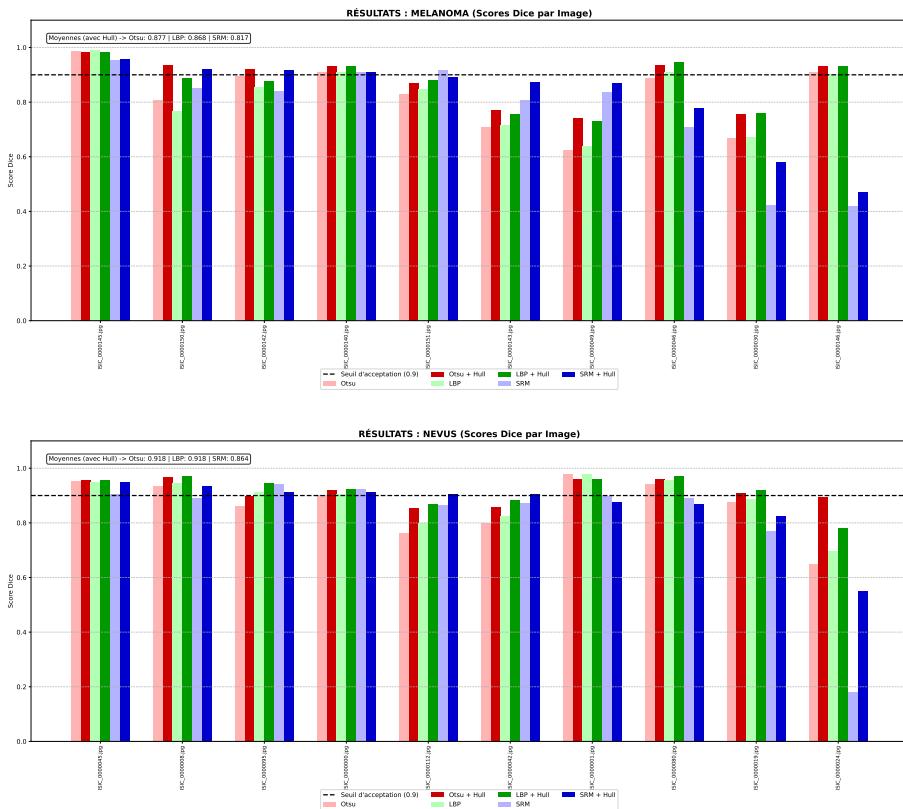


FIGURE 11 – Détail des scores par image. Les mélanomes (haut) présentent une plus grande variance des résultats. On remarque que le SRM (barres bleues) décroche significativement sur plusieurs images complexes par rapport à Otsu (rouge) et LBP (vert).

3.2 Analyse de la robustesse

En observant les barres correspondant aux mélanomes (partie supérieure de la Figure 11), nous constatons que sur les dernières images (souvent les plus difficiles), les barres bleues (SRM) sont nettement plus basses que les barres rouges (Otsu) et vertes (LBP).

- Sur les cas où la lésion est bien contrastée, les trois méthodes se valent.
- Sur les cas "pièges" (bords flous ou hétérogènes), la méthode **LBP Clustering** fait preuve d'une stabilité remarquable, ne descendant que rarement en dessous d'un Dice de 0.8.
- Le **SRM**, malgré nos tentatives d'optimisation (fusion de régions, canal bleu), semble souffrir d'une instabilité : il peut réussir correctement ou échouer sévèrement (barres bleues très basses sur certains échantillons), ce qui pénalise sa moyenne globale.

Ces résultats graphiques suggèrent que la texture (exploitée par LBP) et l'analyse statistique globale (Otsu) sont des descripteurs plus fiables que la croissance de région (SRM) pour ce type d'images dermoscopiques, où les frontières sont souvent mal définies.

Conclusion

Ce projet a permis de comparer trois approches distinctes de segmentation sur des images dermoscopiques variées. L'analyse rigoureuse des résultats graphiques nous mène aux conclusions suivantes :

1. **LBP Clustering (avec Smart Hull) est la méthode la plus performante.** Elle offre le meilleur compromis entre précision et robustesse, aussi bien pour les nævus que pour les mélanomes complexes. L'approche par texture s'avère donc très pertinente.
2. **Otsu Multi-Canal est une alternative solide.** Simple et rapide, elle talonne le LBP en termes de performance une fois couplée à un post-traitement géométrique efficace.
3. **SRM Optimisé s'est montré décevant.** Contrairement à nos attentes, la complexité ajoutée (gestion des régions, fusion) n'a pas conduit à une meilleure segmentation. La méthode s'avère moins stable que les approches globales ou texturelles sur notre jeu de données.

En perspective, pour la mise en place d'un outil de diagnostic assisté, nous recommanderions l'usage du **LBP Clustering** comme algorithme principal. L'étape suivante consisterait à dépasser les méthodes classiques de traitement d'image pour explorer les approches par apprentissage profond (U-Net), qui constituent l'état de l'art actuel.

Références

- [1] T. Lee, V. Ng, R. Gallagher, A. Coldman, D. McLean *DullRazor® : A software approach to hair removal from images* Computers in Biology and Medicine, Vol. 27, No. 6, pp. 533-543, 1997.
- [2] P. G. Cavalcanti, J. Scharcanski, C. B. O. Lopes *Shading attenuation in human skin color images* in *Advances in Visual Computing* (ISVC 2010), G. Bebis et al. (Eds.), Lecture Notes in Computer Science, vol. 6453, Springer, pp. 190-198, 2010.
- [3] P. M. M. Pereira, R. Fonseca-Pinto, R. P. Paiva, P. A. A. Assuncao, L. M. N. Tavora, L. A. Thomaz, S. M. M. Faria *Dermoscopic skin lesion image segmentation based on Local Binary Pattern Clustering : Comparative study* Biomedical Signal Processing and Control, Vol. 59, 101924, 2020.
- [4] M. E. Celebi, H. A. Kingravi, H. Iyatomi, Y. A. Aslandogan, W. V. Stoecker, R. H. Moss, J. M. Malters, J. M. Grichnik, A. A. Marghoob, H. S. Rabinovitz, S. W. Menzies *Border detection in dermoscopy images using statistical region merging* Skin Research and Technology, Vol. 14, No. 3, pp. 347-353, 2008.
- [5] R. Garnavi, M. Aldeen, M. E. Celebi, A. Bhuiyan, C. Dolianitis, G. Varigos *Skin lesion segmentation using color channel optimization and clustering-based histogram thresholding* International Journal of Biomedical and Biological Engineering, Vol. 3, No. 12, pp. 548-557, 2009.